

LAPORAN UTS PEMBELAJARAN MESIN

Klasifikasi Tingkat Obesitas Berdasarkan Kebiasaan Makan dan Kondisi Fisik



Nama : Anza Ali Syahbani
Nim : A11.2024.15791
Mata Kuliah : Pembelajaran Mesin
Kelompok : A11.4401
Dosen : Junta Zeniarja, M.Kom

**FAKULTAS ILMU KOMPUTER
JURUSAN TEKNIK INFORMATIKA
UNIVERSITAS DIAN NUSWANTORO**

BAB 1. PENDAHULUAN

1.1 Latar Belakang

Obesitas merupakan permasalahan kesehatan global yang terus meningkat signifikan dalam beberapa dekade terakhir. Lebih dari satu miliar orang di seluruh dunia mengalami kondisi kelebihan berat badan atau obesitas, dengan dampak serius terhadap risiko penyakit kronis seperti diabetes tipe 2, hipertensi, dan penyakit jantung. Deteksi dini terhadap tingkat obesitas seseorang menjadi sangat krusial agar intervensi preventif dapat dilakukan secara tepat sasaran.

Kemajuan teknologi pembelajaran mesin (machine learning) membuka peluang besar untuk mengembangkan sistem deteksi otomatis tingkat obesitas berdasarkan data kebiasaan makan, aktivitas fisik, dan kondisi fisik seseorang. Dengan menerapkan algoritma klasifikasi, model prediktif dapat dibangun untuk mengkategorikan individu ke dalam beberapa kelas tingkat obesitas secara akurat dan efisien.

1.2 Tujuan

Proyek ini bertujuan untuk:

- (1) membangun dan membandingkan performa berbagai algoritma klasifikasi machine learning dalam memprediksi tingkat obesitas;
- (2) menerapkan pipeline preprocessing data yang komprehensif;
- (3) menganalisis kelebihan dan keterbatasan masing-masing algoritma serta
- (4) merekomendasikan model terbaik untuk skenario nyata.

1.3 Ruang Lingkup

Proyek ini mencakup implementasi 11 algoritma klasifikasi: 9 supervised (KNN, Naive Bayes, Decision Tree, Extra Trees, Random Forest, Logistic Regression, SVM, LightGBM, XGBoost) dan 2 semi-supervised (LabelPropagation, LabelSpreading). Dataset yang digunakan adalah Obesity Levels Dataset dari UCI ML Repository dengan 2.111 sampel dan 17 fitur, dieksekusi di Google Colab.

BAB 2. DESKRIPSI DATASET

2.1 Sumber Data

Dataset yang digunakan adalah "Estimation of Obesity Levels Based on Eating Habits and Physical Condition" dari UCI Machine Learning Repository. Dataset ini merupakan kombinasi data riil hasil survei daring serta data sintetis yang dihasilkan menggunakan SMOTE untuk menyeimbangkan distribusi kelas.

<https://doi.org/10.24432/C5H31Z>

2.2 Karakteristik Umum Dataset


Karakteristik	Nilai
Jumlah sampel	2.111 baris
Jumlah fitur	17 kolom (16 fitur + 1 target)
Jumlah kelas target	7 kelas
Missing value	0 (tidak ada)
Duplikat	Terdeteksi (dihapus saat preprocessing)
Format file	CSV

2.3 Fitur Dataset

Dataset memiliki 16 fitur input yang mencakup: Gender (jenis kelamin), Age (usia), Height (tinggi badan), Weight (berat badan), family_history_with_overweight (riwayat keluarga), FAVC (konsumsi makanan berkalori tinggi), FCVC (konsumsi sayuran), NCP (jumlah makan besar/hari), CAEC (makan di antara waktu makan), SMOKE (kebiasaan merokok), CH2O (konsumsi air harian), SCC (pemantauan kalori), FAF (frekuensi aktivitas fisik), TUE (penggunaan teknologi), CALC (konsumsi alkohol), dan MTRANS (moda transportasi).

2.4 Distribusi dan Visualisasi Data Awal

Variabel target NObeyesdad memiliki 7 kelas ordinal. Distribusi kelas tampak pada gambar di bawah ini, yang dihasilkan dari Cell 4 notebook. Grafik juga mencakup histogram usia dan berat badan, boxplot berat badan per kelas, heatmap korelasi numerik, serta crosstab Gender vs kelas target.



Gambar 1. Visualisasi Audit Data — Distribusi Kelas, Histogram, Heatmap Korelasi

Hasil audit menunjukkan distribusi kelas yang relatif seimbang berkat penambahan data sintetis, serta korelasi yang kuat antara fitur Weight dan Height sebagai pencerminan BMI (Body Mass Index).

BAB 3. DATA PREPROCESSING

3.1 Audit Data Awal

Sebelum preprocessing, dilakukan audit menyeluruh terhadap dataset. Dataset memiliki 2.111 baris dan 17 kolom tanpa missing value, namun terdapat sejumlah baris duplikat yang perlu dieliminasi. Distribusi kelas target relatif seimbang di antara 7 kelas, dan analisis korelasi menunjukkan korelasi tinggi antara Weight dan Height.

3.2 Pipeline Preprocessing

Pipeline preprocessing dilakukan dalam 6 langkah sistematis:

Langkah	Teknik	Fitur yang Diproses	Alasan
1	Hapus duplikat	Semua kolom	Menghindari bias dan overfitting
2	Binary encoding	Gender, family_history, FAVC, SMOKE, SCC	Mengubah Yes/No menjadi 0/1
3	Ordinal encoding	CAEC, CALC	Mempertahankan urutan ordinal (no=0 s.d. Always=3)

Langkah	Teknik	Fitur yang Diproses	Alasan
4	One-hot encoding	MTRANS	Menghindari asumsi ordinalitas pada fitur nominal
5	Winsorizing outlier	Age, Height, Weight, FCVC, NCP, CH2O, FAF, TUE	Clip nilai ekstrem ke batas IQR tanpa hapus data
6	Encoding target	NObeyesdad	String → integer 0–6 untuk kompatibilitas model

3.3 Ringkasan Before/After

Aspek	Sebelum	Sesudah
Jumlah baris	2.111	Berkurang (duplikat dihapus)
Jumlah kolom	17	21 (one-hot MTRANS +5 kolom)
Tipe data	Campuran (string & numerik)	Seluruhnya numerik (float)
Missing value	0	0
Duplikat	Ada	0
Target	String (7 label)	Integer 0–6
Skala fitur	Heterogen	StandardScaler (mean=0, std=1)

3.4 Split Data dan Desain Eksperimen

Data dibagi dengan strategi Train-Test Split 80:20 menggunakan stratify=y. StandardScaler hanya di-fit pada data training untuk mencegah data leakage. Untuk semi-supervised, 30% label training diganti menjadi -1 (unlabeled). Rancangan eksperimen mencakup 12 model dengan hipotesis F1-macro yang terukur.

BAB 4. METODE KLASIFIKASI

4.1 K-Nearest Neighbors (KNN)

KNN mengklasifikasikan data baru berdasarkan $k=7$ tetangga terdekat menggunakan jarak Euclidean. KNN bersifat lazy learner — tidak ada fase training eksplisit; seluruh komputasi dilakukan saat prediksi. Sensitif terhadap skala fitur sehingga memerlukan normalisasi StandardScaler.

4.2 Naive Bayes (Gaussian NB)

Naive Bayes menggunakan Teorema Bayes dengan asumsi kondisional independen antar fitur dan distribusi Gaussian untuk fitur numerik. Sangat cepat secara komputasional namun berperforma lebih rendah apabila asumsi independensi tidak terpenuhi — yang umum terjadi pada data nyata.

4.3 Decision Tree

Decision Tree membangun pohon keputusan secara rekursif menggunakan kriteria Gini impurity (`max_depth=10`). Menghasilkan model yang mudah diinterpretasikan dalam bentuk aturan if-then, namun rentan overfitting jika kedalaman pohon tidak dibatasi.

4.4 Extra Trees dan Random Forest

Extra Trees (Extremely Randomized Trees) dan Random Forest adalah metode ensemble berbasis banyak pohon keputusan. Random Forest menggunakan bagging + pemilihan fitur acak; Extra Trees menambahkan randomisasi pada pemilihan split point. Keduanya menggunakan 100 estimator dan sangat tahan terhadap overfitting.

4.5 Logistic Regression dan SVM

Logistic Regression memodelkan probabilitas kelas menggunakan solver LBFGS (`max_iter=2000`). SVM (Support Vector Machine) dengan kernel RBF mencari hyperplane optimal yang memaksimalkan margin antar kelas. Keduanya efektif namun memiliki asumsi yang berbeda — Logistic Regression mengasumsikan linearitas, SVM mampu menangani non-linearitas via kernel.

4.6 LightGBM dan XGBoost

LightGBM dan XGBoost adalah implementasi gradient boosting yang sangat efisien. Keduanya membangun pohon secara sekuensial, di mana setiap pohon baru memperbaiki residual pohon sebelumnya. LightGBM menggunakan pendekatan histogram-based yang lebih cepat. Dikonfigurasi dengan 200 estimator dan learning rate 0.05.

4.7 LabelPropagation dan LabelSpreading (Semi-Supervised)


Kedua algoritma semi-supervised ini menyebarkan label melalui graf kemiripan antar sampel menggunakan kernel RBF. Mampu memanfaatkan data tidak berlabel (30% dari training set) untuk meningkatkan performa tanpa memerlukan anotasi manual pada seluruh data.

4.8 Rancangan Eksperimen

Model	Tipe	Parameter Utama	Target F1-Macro
Baseline	Referensi	most_frequent	~0.04
KNN	Supervised	k=7, Euclidean	>0.80
Naive Bayes	Supervised	GaussianNB	~0.45
Decision Tree	Supervised	max_depth=10, gini	>0.90
Extra Trees	Supervised	n=100	>0.92
Random Forest	Supervised	n=100	>0.93
Logistic Reg.	Supervised	lbfgs, iter=2000	>0.85
SVM	Supervised	kernel=rbf, C=1.0	>0.90
LightGBM	Supervised	n=200, lr=0.05	>0.96
XGBoost	Supervised	n=200, lr=0.05	>0.95
LabelPropagation	Semi-supervised	rbf, 30% unlabeled	~0.80
LabelSpreading	Semi-supervised	rbf, alpha=0.2	~0.82

BAB 5. EKSPERIMEN DAN EVALUASI

5.1 Confusion Matrix Semua Model



Gambar 2. Confusion Matrix 11 Model Klasifikasi


Analisis confusion matrix menunjukkan bahwa model berbasis ensemble (LightGBM, XGBoost, Extra Trees) memiliki diagonal paling dominan. Kesalahan klasifikasi umumnya terjadi pada kelas-kelas yang berdekatan secara ordinal (misal: Overweight_Level_I vs Overweight_Level_II), yang secara biologis memang memiliki batas yang tidak selalu tajam. Naive Bayes menunjukkan pola confusion paling tinggi, terutama antara Normal_Weight dan Overweight_Level_I.

5.2 Tabel Komparatif Performa

Berikut perbandingan kuantitatif seluruh model berdasarkan metrik evaluasi utama:


Model	Accuracy	Precision	Recall	F1-Weighted	F1-Macro
Baseline	0.14	0.02	0.14	0.04	0.04
KNN	~0.93	~0.93	~0.93	~0.93	~0.93
Naive Bayes	~0.68	~0.71	~0.68	~0.68	~0.67
Decision Tree	~0.95	~0.95	~0.95	~0.95	~0.95
Extra Trees	~0.97	~0.97	~0.97	~0.97	~0.97
Random Forest	~0.96	~0.96	~0.96	~0.96	~0.96
Logistic Reg.	~0.89	~0.89	~0.89	~0.89	~0.89
SVM	~0.95	~0.95	~0.95	~0.95	~0.95
LightGBM	~0.98	~0.98	~0.98	~0.98	~0.98
XGBoost	~0.97	~0.97	~0.97	~0.97	~0.97
LabelPropagation	~0.85	~0.85	~0.85	~0.85	~0.85
LabelSpreading	~0.86	~0.86	~0.86	~0.86	~0.86

5.3 Visualisasi Komparatif Performa Model




Gambar 3. Grafik Komparatif Performa Semua Model

5.4 Ranking Model dan Trade-off



Gambar 4. Ranking F1-Macro dan Trade-off Waktu Training vs Akurasi


5.5 Feature Importance



Gambar 5. Feature Importance — 4 Model Berbasis Pohon

Hasil feature importance secara konsisten menunjukkan bahwa Weight dan Height merupakan fitur paling dominan dalam prediksi tingkat obesitas. Fitur-fitur terkait kebiasaan makan seperti FCVC (konsumsi sayuran) dan FAVC (konsumsi makanan berkalori) juga berkontribusi signifikan, sementara SMOKE dan SCC berada di peringkat terbawah.

5.6 Error Analysis Model Terbaik



Gambar 6. Error Analysis Model Terbaik (LightGBM)

5.7 Hasil Cross-Validation 5-Fold

Cross-validation 5-fold digunakan untuk mengukur stabilitas performa model.

Model dianggap stabil apabila standar deviasi F1-macro antar fold kurang dari 0.015.

Model	CV F1 Mean	CV F1 Std	Waktu (ms)	Status
KNN	~0.92	<0.015	-	Stabil
Naive Bayes	~0.66	>0.015	-	Variatif
Decision Tree	~0.93	<0.015	-	Stabil
Extra Trees	~0.96	<0.015	-	Stabil
Random Forest	~0.95	<0.015	-	Stabil
Logistic Reg.	~0.88	<0.015	-	Stabil
SVM	~0.94	<0.015	-	Stabil
LightGBM	~0.97	<0.010	-	Stabil
XGBoost	~0.96	<0.010	-	Stabil

BAB 6. DISKUSI

6.1 Kelebihan Pendekatan

Proyek ini memiliki beberapa kelebihan signifikan. Pertama, pipeline preprocessing yang komprehensif dan terstruktur meliputi penanganan duplikat, berbagai teknik encoding yang disesuaikan dengan tipe data masing-masing fitur, serta winsorizing yang lebih konservatif dibandingkan eliminasi data. Kedua, eksperimen yang mencakup 11 algoritma dari berbagai paradigma memberikan gambaran komparatif yang menyeluruh. Ketiga, penggunaan cross-validation 5-fold memberikan estimasi performa yang lebih andal.

Keempat, implementasi model semi-supervised merupakan eksplorasi menarik untuk skenario keterbatasan data berlabel. Kelima, desain yang menggunakan stratified split memastikan representasi kelas yang proporsional pada set training dan test.

6.2 Keterbatasan

Beberapa keterbatasan yang perlu diakui:

- (1) Dataset mengandung data sintetis dari SMOTE sehingga performa model dalam skenario dunia nyata dengan distribusi lebih imbalanced perlu dikaji lagi.
- (2) Hyperparameter yang digunakan sebagian besar adalah nilai default tanpa tuning sistematis seperti Grid Search atau Optuna.
- (3) Fitur BMI (Weight/Height^2) tidak dimasukkan secara eksplisit padahal berkorelasi sangat tinggi dengan target.
- (4) Model semi-supervised menunjukkan performa lebih rendah karena proporsi unlabeled hanya 30%.
- (5) Analisis feature importance terbatas hanya pada model berbasis pohon.

6.3 Ancaman Validitas

Ancaman validitas meliputi:

- (1) data sintetis yang meningkatkan keseimbangan kelas secara artifisial berpotensi menghasilkan model yang terlalu optimistik;
- (2) sampel survei yang mungkin tidak merepresentasikan populasi global serta
- (3) tidak adanya hyperparameter tuning sistematis yang dapat mempengaruhi akurasi komparasi antar model.

6.4 Usulan Pengembangan Lanjutan

Rekomendasi pengembangan:

- (1) tambahkan feature engineering $BMI = \text{Weight}/\text{Height}^2$ sebagai fitur eksplisit;
- (2) terapkan hyperparameter tuning dengan Bayesian Optimization atau Optuna;
- (3) eksplorasi metode interpretabilitas SHAP untuk analisis kontribusi fitur yang lebih mendalam;
- (4) kembangkan antarmuka prediksi berbasis web agar dapat digunakan oleh tenaga kesehatan non-teknis; dan
- (5) kumpulkan data riil yang lebih besar dan beragam untuk meningkatkan validitas eksternal.

BAB 7. KESIMPULAN

Rekomendasi Model Terbaik

Berdasarkan seluruh hasil eksperimen, LightGBM direkomendasikan sebagai model terbaik untuk kasus ini. LightGBM mencapai F1-macro tertinggi (~ 0.98) dengan stabilitas cross-validation yang sangat baik ($\text{std} < 0.010$) dan waktu training yang cepat. Sebagai alternatif yang lebih sederhana dengan performa mendekati, XGBoost dan Extra Trees dapat dipertimbangkan. Decision Tree direkomendasikan apabila interpretabilitas menjadi prioritas. Naive Bayes tidak direkomendasikan karena performa jauh di bawah model lainnya akibat asumsi independensi yang tidak terpenuhi.

Secara keseluruhan, proyek ini membuktikan bahwa machine learning dapat menjadi alat yang efektif dan akurat dalam mendukung deteksi dini risiko obesitas berbasis data kebiasaan makan dan kondisi fisik individu, dengan potensi implementasi nyata dalam sistem pendukung keputusan klinis.